

# 검색 관심도는 YouTube 성과로 이어질까?

Google Trends · Naver DataLab · YouTube Data API를 HDFS/Spark/Hive 파이프라인으로 분석

20 keywords

600 search rows

581 unique videos

HDFS · Spark · Hive

58,787 comments · 120.5MB raw

## 한 줄 요약

검색 플랫폼별 관심도와 YouTube 영상 성과의 관계를 분석하고, 댓글 raw 데이터로 수집 규모를 보강했다.

홍성분 · 60211705 · 데이터사이언스

GitHub: [github.com/hellobean27/bigdata-search-youtube-analysis](https://github.com/hellobean27/bigdata-search-youtube-analysis)

# 1. 문제 정의와 프로젝트 동기

어떤 데이터를 사용해 어떤 문제를 풀었는가?

## 사용 데이터

Google Trends: 최근 30일 검색 관심도  
Naver DataLab: 최근 30일 검색 관심도  
YouTube API: 최근 업로드 영상 성과  
YouTube 댓글 raw: 58,787개

## 분석 질문

검색 관심도가 높은 키워드는 YouTube에서도 높은 조회수·좋아요·댓글로 나타나는가?

## 빅데이터 주제 적합성

서로 다른 플랫폼 데이터를 API/CSV로 수집하고, HDFS raw 120.5MB 이상 저장 후 Spark-Hive 기반으로 분석

## 키워드 설계: 4개 분야 × 5개 = 20개

### IT/경제

AI · 삼성 · 반도체 · 엔비디아 · 환율

### 정치/사회

선거 · 대통령 · 대선 · 국회 · 여론조사

### 엔터/문화

리센스 · 아이브 · 에스파 · 뉴진스 · 르세라핌

### 지역



충주 · 여수 · 서울 · 거제 · 부산

## 핵심 주의점

YouTube 조회수는 “최근 30일 조회수”가 아니라 수집 시점 기준 누적 조회수입니다. 따라서 일평균 조회수를 함께 사용했고, 댓글 raw는 보조 반응 데이터로 집계했습니다.

## 2. 시스템 아키텍처

데이터 수집 → 저장 → 전처리 → 분석 → 결과 공유



# 3. 핵심 처리·분석 방법

일평균 조회수와 상관관계로 “최근 반응 속도”를 비교

## 처리 기준

| 단계 | 처리 내용                      | 산출물                            |
|----|----------------------------|--------------------------------|
| 1  | 20개 키워드 검색 관심도 수집          | search_interest_20keywords.csv |
| 2  | YouTube 최근 업로드 영상 검색       | 600 search rows                |
| 3  | 영상 통계 조회 및 병합              | 581 unique videos              |
| 4  | Spark groupBy 집계           | keyword/category summary       |
| 5  | Hive SQL 조회                | TOP 10-분야별-상관관계                |
| 6  | YouTube 댓글 raw 수집·Spark 집계 | 58,787 comments / 120.5MB      |

### 핵심 지표

$views\_per\_day = view\_count / days\_since\_upload$

누적 조회수 편향을 줄이기 위해 업로드 후 경과일로 보정

### 분석 단위

키워드별  
분야별  
검색 플랫폼별

### 성과 지표


평균 조회수  
일평균 조회수  
100만 이상 비율  
댓글 반응 보조지표

### 상관분석

Google/Naver 관심도와 YouTube 성과 지표 간 Pearson 상관계수 계산  
댓글 raw는 별도 Spark 집계로 보조 분석


## 4. 가장 흥미로운 분석 결과

Google은 YouTube 성과와 양의 관계, Naver는 다르게 나타남



### Insight 1

Google 관심도 ↔ 평균 일조회수 상관계수 = 0.584  
Naver 관심도 ↔ 평균 일조회수 상관계수 = -0.152



### Insight 2

IT/경제: 평균 일조회수 1위(약 301,491)  
엔터/문화: 100만 이상 비율 1위(약 83.9%)

## 5. 한계와 확장 방향

GitHub 공개 저장소로 재현 가능성 확보

### 한계 1: 조회수 기준

YouTube API 조회수는 최근 30일 조회수가 아니라 수집 시점 기준 누적 조회수.  
→ 일평균 조회수로 보정

### 한계 2: 한국 영상 판별

regionCode=KR, relevanceLanguage=ko는 한국 관련성을 높이지만 한국 제작 영상만 보장하지 않음.

### 확장 방향

일별 조회수와 댓글 raw를 누적 수집하면 검색 추이와 영상 반응의 시차 분석 가능

### 재현 가능성

- GitHub repository에 README, 수집 코드, Spark 분석 코드, 결과 CSV 업로드
- HDFS raw 120.5MB 및 raw/results 경로, Spark/Hive 수행 캡처 확보
- 댓글 raw 원본은 HDFS에 저장하고 GitHub에는 1,000줄 샘플 공개



### GitHub Repository

hellobean27/  
bigdata-search-youtube-  
analysis

코드·결과 CSV·샘플 공개