

빅데이터 프로그래밍 기말 프로젝트

최종 보고서

최근 30 일 검색 관심도와 YouTube 최근 업로드 영상 성과 지표의 관계 분석

Google Trends · Naver DataLab · YouTube Data API · HDFS · Spark · Hive

항목	내용
작성자	홍성본 / 60211705
분석 기간	2026-05-10 ~ 2026-06-08
분석 키워드	20 개(IT/경제, 정치/사회, 엔터/문화, 지역)
YouTube 수집 규모	YouTube 수집 규모: 검색 결과 600 개, 고유 영상 581 개, 댓글 raw 58,787 개 HDFS raw 규모: 약 120.5MB
GitHub	https://github.com/hellobean27/bigdata-search-youtube-analysis

GitHub Repository QR



1. 문제 정의

1.1 프로젝트 배경과 분석 목적

최근 사용자는 특정 이슈나 키워드에 관심이 생기면 Google, Naver 와 같은 검색 플랫폼에서 정보를 탐색하고, 동시에 YouTube 에서 관련 영상을 소비한다. 그러나 검색 플랫폼에서 관심도가 높게 나타난 키워드가 YouTube 에서도 높은 조회수, 좋아요 수, 댓글 수 등 영상 성과로 이어지는지는 별도의 데이터 결합과 분석 없이는 확인하기 어렵다.

본 프로젝트는 Google Trends 와 Naver DataLab 의 최근 30 일 검색 관심도 데이터와 같은 기간에 업로드된 YouTube 영상 성과 지표를 결합하여, 검색 관심도와 YouTube 영상 소비 지표 사이의 관계를 분석하는 것을 목표로 한다. 핵심 분석 질문은 “검색 관심도가 높은 키워드는 YouTube 에서도 높은 영상 성과를 보이는가?”이다.

1.2 사용 데이터와 분석 질문

데이터	출처	주요 항목	수집 방식
검색 관심도	Google Trends	키워드별 상대 검색 관심도	CSV 다운로드
검색 관심도	Naver DataLab	키워드별 검색어 트렌드 ratio	API 호출
영상 성과	YouTube Data API v3	제목, 채널명, 업로드일, 조회수, 좋아요 수, 댓글 수	API 호출
분석 결과	Spark/Hive	키워드별/분야별 요약, 상관관계	HDFS 저장 및 SQL 조회
사용자 반응 데이터	YouTube Data API commentThreads.list	댓글 ID, 댓글 내용, 댓글 좋아요 수, 답글 수	API 호출 / JSONL 저장

분석 질문은 단순 조회가 아니라 플랫폼별 검색 관심도와 영상 성과 지표의 관계를 확인하는 방향으로 설정하였다. 구체적으로 Google 관심도와 YouTube 평균 일조회수의 관계, Naver 관심도와 YouTube 성과의 관계, 분야별 영상 성과 차이를 분석하였다.

1.3 빅데이터 프로그래밍 프로젝트로서의 적절성

이 프로젝트는 여러 출처에서 수집한 데이터를 하나의 파이프라인으로 통합하고, HDFS 에 저장한 뒤 Spark 와 Hive 를 이용해 처리·분석했다는 점에서 빅데이터 프로그래밍 프로젝트로 적절하다. 데이터 수집, 분산 저장, 전처리, 집계, SQL 분석, 결과 시각화까지의 흐름을 구현했으며, GitHub repository 에 코드와 결과를 정리하여 재현 가능성을 확보하였다.

2. 시스템 아키텍처

전체 시스템은 데이터 수집, HDFS 저장, Spark 전처리 및 집계, Hive SQL 분석, 결과 정리 단계로 구성하였다. 수집 단계에서는 Google Trends CSV, Naver DataLab API, YouTube Data API 를 사용했고, 처리 단계에서는 HDFS 와 Spark DataFrame 을 사용하였다.



결과 산출: keyword_summary / category_summary / correlation_result → 보고서·발표자료·GitHub 재현 자료

2.1 기술 스택과 역할

기술	역할	프로젝트 내 사용 내용
Python/Colab	API 수집 및 CSV 생성	Naver DataLab, YouTube Data API 호출 및 결과 저장
Google Trends	검색 관심도 데이터	최근 30 일 키워드별 상대 관심도 CSV 다운로드
Naver DataLab API	검색어 트렌드 데이터	keywordGroups 기반 최근 30 일 ratio 수집
YouTube Data API v3	영상 메타데이터/통계 수집	search.list 로 영상 검색, videos.list 로 조회수 등 조회
HDFS	분산 파일 저장	raw, processed, results 경로에 CSV 와 Spark 결과 저장
Spark DataFrame	전처리 및 집계	타입 변환, 중복 제거, 키워드/분야별 집계, 상관관계 계산
Hive	SQL 기반 분석	Spark 결과를 외부 테이블로 연결하여 조회
GitHub	산출물 공유	README, Spark 코드, 결과 CSV 공개

3. 데이터 수집 방법

3.1 키워드 구성과 기간

분석 대상은 총 20 개 키워드이며, 네 가지 분야로 나누어 구성하였다. 분석 기간은 Google Trends 및 Naver DataLab 기준 2026-05-10 부터 2026-06-08 까지이다. YouTube 영상도 같은 기간에 업로드된 영상을 대상으로 수집하였다.

분야	키워드
IT/경제	AI, 삼성, 반도체, 엔비디아, 환율
정치/사회	선거, 대통령, 대선, 국회, 여론조사
엔터/문화	리센스, 아이브, 에스파, 뉴진스, 르세라핌
지역	충주, 여수, 서울, 거제, 부산

3.2 Google/Naver 검색 관심도 수집

Google Trends 와 Naver DataLab 은 절대 검색량이 아니라 상대 검색 관심도 또는 ratio 형태의 값을 제공한다. 따라서 본 보고서에서는 이를 검색량이 아니라 검색 관심도로 표현하였다. Google Trends 는 비교 묶음마다 값이 정규화되므로, 모든 묶음에 공통 기준 키워드인 “삼성”을 포함하고 anchor 방식으로 그룹 간 스케일을 보정하였다. Naver DataLab 도 동일한 키워드 묶음 구조로 수집하였다.

그룹	키워드
group1	삼성, AI, 반도체, 엔비디아, 환율
group2	삼성, 선거, 대통령, 대선, 국회
group3	삼성, 여론조사, 리센스, 아이브, 에스파
group4	삼성, 뉴진스, 르세라핌, 충주, 여수
group5	삼성, 서울, 거제, 부산

3.3 YouTube API 수집

YouTube 데이터는 search.list 와 videos.list 를 나누어 수집하였다. 먼저 search.list 로 키워드별 최근 30 일 업로드 영상을 조회하고, 이후 videos.list 로 해당 영상의 조회수, 좋아요 수, 댓글 수를 수집하였다. 수집 조건은 regionCode=KR, relevanceLanguage=ko, order=viewCount, 키워드별 최대 30 개 영상으로 설정하였다.

추가로 YouTube 영상에 대한 사용자 반응 데이터를 보강하고, 누적 100MB 이상 raw 데이터 확보 조건을 충족하기 위해 YouTube Data API 의 commentThreads.list 를 사용하여 댓글 raw 데이터를 JSONL 형식으로 수집하였다. 수집 결과 댓글 58,787 개, 처리 영상 55 개, 약 120.11MB 규모의 댓글 raw JSONL 데이터를 확보하였다. 해당 파일을 HDFS raw/comments 경로에 업로드한 결과, HDFS raw 전체 용량은 약 120.5MB 로 확인되었다.

항목	확인된 값
검색 키워드 수	20 개
YouTube 검색 결과 행 수	600 개
고유 YouTube 영상 수	581 개
키워드별 수집 영상 수	최대 30 개
카테고리 수	4 개
YouTube 댓글 raw 수집 수	58,787 개
HDFS raw 업로드 데이터	기존 CSV 7 개 + YouTube 댓글 raw JSONL 1 개
댓글 수집 대상 영상 수	55 개
댓글 raw JSONL 용량	약 120.11MB
HDFS raw 전체 용량	약 120.5MB

4. 데이터 처리 및 분석 방법

4.1 HDFS 저장

수집한 CSV 파일은 HDP Sandbox 환경의 HDFS 에 업로드하였다. raw, processed, results 경로를 구분하여 원본 데이터와 Spark 처리 결과를 관리하였다.

HDFS 경로	역할
/user/maria_dev/search_youtube/raw	수집 원본 CSV 저장
/user/maria_dev/search_youtube/processed	Spark 정제 결과 저장
/user/maria_dev/search_youtube/results	Spark 분석 결과 저장

4.2 Spark 전처리 및 집계

Spark 분석 스크립트는 GitHub 의 src/pipeline/spark_analyze_no_hive.py 에 업로드하였다. 이 스크립트는 HDFS raw 경로에서 병합 CSV 를 읽고, 숫자형 타입 변환, 중복 제거, 100 만 조회수 이상 여부 계산, 키워드별/분야별 집계, 상관관계 계산을 수행한다.

추가로 수집한 YouTube 댓글 raw JSONL 데이터는 spark_analyze_comments.py 를 통해 Spark 로 처리하였다. 해당 스크립트는 HDFS raw/comments 경로의 youtube_comments_raw.jsonl 파일을 읽고, 기존 YouTube 영상 병합 데이터와 video_id 기준으로 연결한 뒤 키워드와 분야별로 수집 댓글 수, 댓글이 수집된 영상 수, 평균 댓글 좋아요 수, 평균 답글 수, 평균 댓글 길이를 집계하였다. 이 결과는 핵심 상관관계 분석을 보조하는 사용자 반응 데이터 분석으로 활용하였다.

처리 단계	핵심 로직
타입 변환	view_count, like_count, comment_count, google_interest, naver_interest 등을 double 로 변환
중복 제거	keyword, video_id 기준 dropDuplicates 수행
보정 지표	views_per_day = view_count / days_since_upload
이진 지표	is_million_view = view_count >= 1,000,000
집계	keyword, category 기준 평균 조회수, 평균 일조회수, 100 만 이상 비율 계산
상관관계	google_interest/naver_interest 와 YouTube 성과 지표 간 corr 계산
댓글 raw 집계	YouTube 댓글 JSONL 을 Spark 로 읽고 video_id 기준 연결 후 키워드/분야별 댓글 반응 지표 집계

4.3 Hive 분석

Spark 결과 파일은 Hive 외부 테이블로 연결하였다. 생성한 테이블은 keyword_summary, category_summary, correlation_result 이며, HiveQL 을 이용해 키워드별 TOP 10, 분야별 성과 요약, 상관관계를 조회하였다. Beeline 터미널에서 한글이 일부 ??로 표시되는 인코딩 문제가 있었으나, 수치 결과는 정상 조회되었다.

Hive 테이블	설명
keyword_summary	키워드별 YouTube 성과 요약
category_summary	분야별 YouTube 성과 요약
correlation_result	검색 관심도와 YouTube 성과 지표의 상관관계

5. 분석 결과 및 인사이트

5.1 결과 1: Google 관심도는 YouTube 성과와 양의 관계를 보임

분석 질문: Google 검색 관심도가 높은 키워드는 YouTube 에서도 높은 영상 성과를 보이는가?

키워드별 집계 결과를 기준으로 Google 관심도와 YouTube 성과 지표 간 상관관계를 계산하였다. 그 결과 Google 관심도는 평균 조회수, 평균 일조회수, 평균 좋아요 수, 평균 댓글 수와 모두 양의 상관관계를 보였다.

YouTube 성과 지표	Google 관심도 상관계수	Naver 관심도 상관계수
평균 조회수	0.504	-0.206
평균 일조회수	0.584	-0.152
100 만 이상 비율	0.348	-0.387
평균 좋아요	0.449	-0.233
평균 댓글	0.456	-0.102




그림 2. Google/Naver 검색 관심도와 YouTube 성과 지표 간 상관계수

인사이트: Google 관심도와 평균 일조회수의 상관계수는 0.584 로, 본 데이터에서는 Google 검색 관심도가 높은 키워드가 YouTube 에서도 상대적으로 빠른 조회 성과를 보이는 경향이 있었다. 또한 평균 조회수와 상관계수 0.504 보다 평균 일조회수와 관계가 더 높게 나타났기 때문에, 최근 업로드 영상의 성과를 비교할 때 업로드 후 경과일을 보정한 지표가 더 적절할 수 있다.

5.2 결과 2: Naver 관심도는 YouTube 성과와 뚜렷한 양의 관계를 보이지 않음

분석 질문: Naver 검색 관심도가 높은 키워드는 YouTube 영상 성과도 높은가?

Naver 관심도는 평균 조회수(-0.206), 평균 일조회수(-0.152), 100 만 이상 비율(-0.387)과 양의 관계를 보이지 않았다. 이 결과는 Naver 에서 검색 관심이 높은 키워드가 반드시 YouTube 영상 소비로 이어지지는 않음을 보여준다.

인사이트: Naver 검색은 정보 탐색형 수요가 강할 수 있고, YouTube 는 영상 소비형 관심이나 추천 알고리즘, 팬덤, 콘텐츠 형식의 영향을 더 크게 받을 수 있다. 따라서 검색 플랫폼별 관심도는 서로 다른 의미를 가지며, Google 과 Naver 결과를 단순 합산하기보다 분리해서 해석하는 것이 타당하다.

5.3 결과 3: 분야별 YouTube 성과 차이

분야	영상 수	평균 조회수	평균 일조회수	100 만 이상 비율
IT/경제	148	2,976,690	301,491	54.7%
엔터/문화	149	3,225,323	252,233	83.9%
정치/사회	148	1,422,560	206,433	61.5%
지역	150	1,384,853	158,769	57.3%




그림 3. 분야별 평균 일조회수




그림 4. 분야별 100 만 조회수 이상 영상 비율

인사이트: IT/경제 분야는 평균 일조회수가 약 301,491 회로 가장 높았다. 엔터/문화 분야는 100 만 조회수 이상 영상 비율이 약 83.9%로 가장 높았다. 이는 IT/경제 분야가 최근 반응 속도 측면에서 강하고, 엔터/문화 분야는 고조회수 영상이 넓게 분포하는 특성을 가진다는 점을 시사한다.

5.4 키워드별 평균 일조회수 TOP 10

순위	키워드	분야	평균 일조회수	100 만 이상 비율
1	AI	IT/경제	899,696	1.000
2	선거	정치/사회	329,419	0.933
3	리센느	엔터/문화	325,492	1.000
4	에스파	엔터/문화	323,375	0.900
5	국회	정치/사회	291,610	0.400
6	르세라핌	엔터/문화	289,923	1.000
7	서울	지역	282,380	0.800
8	부산	지역	222,686	0.867
9	엔비디아	IT/경제	210,674	0.300
10	삼성	IT/경제	202,702	0.967




그림 5. 키워드별 평균 일조회수 TOP 10

AI는 평균 일조회수 약 899,696 회로 가장 높게 나타났다. 또한 100 만 이상 비율도 1.000으로 나타나, 본 프로젝트 기간과 키워드 구성에서는 AI 관련 영상의 최근 성과가 매우 강하게 나타났다.

6. 한계와 확장 가능성

6.1 데이터 수집 범위의 한계

본 프로젝트는 최근 30 일, 20 개 키워드, 키워드별 최대 30 개 영상으로 분석 범위를 제한하였다. 따라서 전체 사회적 관심사나 장기적인 플랫폼 이용 행태를 대표한다고 보기는 어렵다. 향후에는 기간을 3 개월, 6 개월, 1 년 단위로 늘리고 키워드 수를 확대하면 더 안정적인 결과를 얻을 수 있다.

6.2 YouTube 누적 조회수의 한계

YouTube Data API 에서 수집한 조회수는 최근 30 일 동안 발생한 조회수가 아니라 수집 시점 기준 누적 조회수이다. 본 프로젝트에서는 업로드 후 경과일을 나눈 평균 일조회수를 사용해 일부 보정했지만, 실제 일별 조회수 증가량을 직접 측정한 것은 아니다. 향후 동일 영상의 조회수를 매일 반복 수집하면 더 정확한 시계열 분석이 가능하다.

6.3 API 와 정규화 지표의 한계

regionCode=KR, relevanceLanguage=ko 조건은 한국 관련 영상 수집을 보조하지만 한국 제작 영상만을 완전히 보장하지 않는다. 일부 외국어 영상이나 해외 채널 영상이 포함될 수 있다. 또한 Google Trends 와 Naver DataLab 은 절대 검색량이 아닌 정규화된 관심도 지표를 제공하므로, 결과는 절대 검색량과 조회수의 직접 비교가 아니라 상대 관심도와 YouTube 성과 지표의 탐색적 관계로 해석해야 한다.

6.4 확장 가능성

확장 방향으로 Kafka 를 이용한 실시간 수집, Spark Streaming 기반 트렌드 분석, YouTube 댓글 감성 분석, 뉴스·SNS·쇼핑 플랫폼 데이터 결합, Zeppelin 또는 Grafana 기반 대시보드 시각화가 있다. 또한 Google 과 Naver 외에 다른 검색·소셜 플랫폼 데이터를 추가하면 플랫폼별 관심도 차이를 더 정밀하게 분석할 수 있다.

7. GitHub Repository 및 재현 가능성

본 프로젝트의 GitHub repository 는 다음과 같다: <https://github.com/hellobean27/bigdata-search-youtube-analysis>

경로	역할
README.md	프로젝트 문제 정의, 기술 스택, 구현 계획 설명
data/README.md	데이터 출처, 수집 기준, 해석 주의사항 설명
src/pipeline/spark_analyze_no_hive.py	HDFS 데이터를 읽어 Spark 분석을 수행하는 핵심 코드
results/spark_keyword_summary.csv	키워드별 분석 결과
results/spark_category_summary.csv	분야별 분석 결과
results/spark_correlation.csv	검색 관심도와 YouTube 성과 지표의 상관관계 결과
data/sample/youtube_comments_raw_sample_1000.jsonl	YouTube 댓글 raw 데이터 샘플 1,000 줄
data/sample/youtube_comments_summary.csv	댓글 raw 수집 요약 파일
src/ingest/collect_youtube_comments.py	YouTube 댓글 raw JSONL 수집 코드
src/pipeline/spark_analyze_comments.py	YouTube 댓글 raw 데이터를 Spark 로 집계하는 보조 분석 코드
results/spark_comment_keyword_summary.csv	키워드/분야별 댓글 반응 집계 결과

7.1 실행 방법 요약

HDP Sandbox 또는 강의 실습 환경에서 다음 순서로 재현할 수 있다. 계정명과 HDFS 경로는 실습 환경에 따라 수정이 필요할 수 있다.

```
# 1. HDFS 경로 생성
hdfs dfs -mkdir -p /user/maria_dev/search_youtube/raw
hdfs dfs -mkdir -p /user/maria_dev/search_youtube/processed
hdfs dfs -mkdir -p /user/maria_dev/search_youtube/results

# 2. 기존 csv 원본 데이터 업로드
hdfs dfs -put -f *.csv /user/maria_dev/search_youtube/raw/

# 3. 영상 성과 분석 Spark 실행
nohup env PYTHONIOENCODING=utf-8 spark-submit --master 'local[2]' spark_analyze_no_hive.py >
spark_run.log 2>&1 &

# 4. 영상 성과 분석 결과 확인
hdfs dfs -ls -R /user/maria_dev/search_youtube/results
```



```
# 5. YouTube 댓글 raw 데이터 업로드
hdfs dfs -mkdir -p /user/maria_dev/search_youtube/raw/comments
hdfs dfs -put -f youtube_comments_raw.jsonl /user/maria_dev/search_youtube/raw/comments/
hdfs dfs -put -f youtube_comments_summary.csv /user/maria_dev/search_youtube/raw/comments/
hdfs dfs -put -f youtube_comments_error_log.csv /user/maria_dev/search_youtube/raw/comments/

# 6. HDFS raw 전체 용량 확인
hdfs dfs -du -h -s /user/maria_dev/search_youtube/raw

# 7. 댓글 raw 분석 Spark 실행
nohup env PYTHONIOENCODING=utf-8 spark-submit --master 'local[2]' spark_analyze_comments.py >
spark_comments_run.log 2>&1 &

# 8. 댓글 분석 결과 확인
hdfs dfs -ls -R /user/maria_dev/search_youtube/results/spark_comment_keyword_summary

# 9. Hive 실행 후 외부 테이블 생성 및 SELECT 쿼리 수행
hive
```

위 명령어는 HDP Sandbox의 maria_dev 계정 기준 예시이며, 실제 실행 시 로컬 파일 위치와 계정명은 환경에 맞게 수정해야 한다. 대용량 댓글 raw 원본은 GitHub에 업로드하지 않고 HDFS에 저장하며, GitHub에는 data/sample 경로에 샘플 파일만 업로드하였다.

재현 가능성을 위해 API 키는 코드에 직접 포함하지 않았으며, 최종 repository에는 Spark 처리 코드와 결과 CSV를 업로드하였다. 원본 수집 데이터 전체와 API 키는 보안 및 용량 문제로 별도 관리하는 것이 적절하다.

8. 참고 자료 및 AI 도구 사용 명시

8.1 참고 자료

출처	문서	URL
Google Trends Help	Compare Trends search terms	https://support.google.com/trends/answer/4359550
Naver Developers	DataLab 통합 검색어 트렌드 API	https://developers.naver.com/docs/serviceapi/datalab/search/search.md
YouTube Data API	search.list	https://developers.google.com/youtube/v3/docs/search/list
YouTube Data API	videos.list	https://developers.google.com/youtube/v3/docs/videos/list
Apache Hadoop	HDFS Documentation	https://hadoop.apache.org/docs/
Apache Spark	Spark SQL/DataFrame Documentation	https://spark.apache.org/docs/latest/sql-programming-guide.html
Apache Hive	Hive Documentation	https://hive.apache.org/

8.2 AI Tool Usage

ChatGPT: 프로젝트 요구사항 이해, 주제 구체화, API 수집 절차 정리, Spark/Hadoop/Hive 오류 디버깅 지원, 보고서 목차 검토 및 문장 표현 다듬기에 활용하였다.

ChatGPT의 제안은 그대로 제출하지 않고, 실제 API 수집 결과, HDFS/Spark/Hive 실행 결과, GitHub 산출물을 기준으로 검토·수정하였다.

최종 코드 실행, 데이터 수집, 결과 확인, 캡처 확보 및 제출 여부 판단은 작성자가 직접 수행하였다.

Appendix. 제출 전 확인한 실행 증빙

증빙 항목	확인 내용
HDFS raw 업로드	CSV 7 개 + YouTube 댓글 raw JSONL 업로드, HDFS raw 전체 약 120.5MB 확인
Spark 실행	Spark analysis completed successfully 및 Comment analysis completed successfully 메시지 확인
Spark 결과 저장	기존 3 개 분석 결과 + spark_comment_keyword_summary 및 _SUCCESS 생성
Hive 테이블 생성	SHOW TABLES 결과 category_summary, correlation_result, keyword_summary 확인
Hive 쿼리 조회	키워드 TOP 10, 분야별 요약, 상관관계 결과 조회 확인

1. HDFS raw 업로드

```

~ hdfs dfs -ls -R /user/maria_dev/search_youtube/raw | head -80
-rwxr-xr-x 1 maria_dev hdfs 743 2026-06-08 18:39 /user/maria_dev/search_youtube/raw/category_summary_20keywords.csv
drwxr-xr-x - maria_dev hdfs 0 2026-06-08 22:14 /user/maria_dev/search_youtube/raw/comments
-rw-r--r-- 1 maria_dev hdfs 4 2026-06-08 22:14 /user/maria_dev/search_youtube/raw/comments/youtube_comments_error_log.csv
-rw-r--r-- 1 maria_dev hdfs 125940139 2026-06-08 22:14 /user/maria_dev/search_youtube/raw/comments/youtube_comments_raw.jsonl
-rw-r--r-- 1 maria_dev hdfs 6877 2026-06-08 22:14 /user/maria_dev/search_youtube/raw/comments/youtube_comments_summary.csv
-rwxr-xr-x 1 maria_dev hdfs 1084 2026-06-08 18:39 /user/maria_dev/search_youtube/raw/correlation_20keywords.csv
-rwxr-xr-x 1 maria_dev hdfs 3114 2026-06-08 18:39 /user/maria_dev/search_youtube/raw/keyword_summary_20keywords.csv
-rwxr-xr-x 1 maria_dev hdfs 2011 2026-06-08 18:39 /user/maria_dev/search_youtube/raw/search_interest_20keywords.csv
-rwxr-xr-x 1 maria_dev hdfs 88227 2026-06-08 18:39 /user/maria_dev/search_youtube/raw/youtube_search_20keywords.csv
-rwxr-xr-x 1 maria_dev hdfs 171376 2026-06-08 18:39 /user/maria_dev/search_youtube/raw/youtube_trends_merged_20keywords.csv
-rwxr-xr-x 1 maria_dev hdfs 96594 2026-06-08 18:39 /user/maria_dev/search_youtube/raw/youtube_video_stats_20keywords.csv
~ hdfs dfs -du -h -s /user/maria_dev/search_youtube/raw
120.5 M 120.5 M /user/maria_dev/search_youtube/raw
~

```

2. Spark 실행

```

===== Spark Category Summary =====
+-----+-----+-----+-----+-----+-----+-----+-----+
|category|keyword_count|video_count|avg_view_count|median_view_count|avg_like_count|avg_comment_count|million_view_count|avg_views_per_day|median_views_per_day|million_view_ratio|
+-----+-----+-----+-----+-----+-----+-----+-----+
|IT/경 제|5|148|2976689.8733333335|1121850.0|42718.99310344827|1781.6644295302012|81|30149|0.53011759993|98708.95454545454|0.5472972972972973|
|연 터 /분 화|5|149|3225322.8066666666|2293298.0|56789.29931972789|1807.1466666666668|125|252|232.77481550246|157464.5|0.8389261744966443|
|정 지 /사 회|5|148|1422559.94|1290169.0|39716.56375838926|2098.3691275167785|91|206|433.47046917205|140035.0|0.6148648648648649|
|지 역|5|150|1384853.4866666666|1269458.0|27694.11724137931|2000.5266666666666|86|15876|9.06417743227|95798.57142857143|0.5733333333333334|
+-----+-----+-----+-----+-----+-----+-----+-----+

===== Spark Correlation Result =====
+-----+-----+-----+
|metric|google_corr|naver_corr|
+-----+-----+-----+
|avg_view_count|0.5035877090970381|-0.20612896851800502|
|avg_views_per_day|0.5835128260163255|-0.15166082728076344|
|million_view_ratio|0.34843432294270194|-0.38733578762287285|
|avg_like_count|0.4486770768902787|-0.2327290582778656|
|avg_comment_count|0.4556382843923419|-0.10173842438055031|
+-----+-----+-----+

Spark analysis completed successfully.

~ scripts tail -50 spark comments run.log
nohup: ignoring input
Comment analysis completed successfully.

```

3. Spark 결과 저장

```

➔ scripts hdfs dfs -ls -R /user/maria_dev/search_youtube/results
drwxrwxrwx - maria_dev hdfs 0 2026-06-08 19:09 /user/maria_dev/search_youtube/results/spark_category_summary
-rwxrwxrwx 1 maria_dev hdfs 0 2026-06-08 19:09 /user/maria_dev/search_youtube/results/spark_category_summary/_SUCCESS
-rwxrwxrwx 1 maria_dev hdfs 722 2026-06-08 19:09 /user/maria_dev/search_youtube/results/spark_category_summary/part-00000-8d1ef
e9b-49a7-4d78-80fd-615682531a90-c000.csv
drwxr-xr-x - maria_dev hdfs 0 2026-06-08 22:18 /user/maria_dev/search_youtube/results/spark_comment_keyword_summary
-rw-r--r-- 1 maria_dev hdfs 0 2026-06-08 22:18 /user/maria_dev/search_youtube/results/spark_comment_keyword_summary/_SUCCESS
-rw-r--r-- 1 maria_dev hdfs 1438 2026-06-08 22:18 /user/maria_dev/search_youtube/results/spark_comment_keyword_summary/part-0000
0-lb208d22-5f5c-44a1-81f0-3650b750d336-c000.csv
drwxrwxrwx - maria_dev hdfs 0 2026-06-08 19:09 /user/maria_dev/search_youtube/results/spark_correlation
-rwxrwxrwx 1 maria_dev hdfs 0 2026-06-08 19:09 /user/maria_dev/search_youtube/results/spark_correlation/_SUCCESS
-rwxrwxrwx 1 maria_dev hdfs 315 2026-06-08 19:09 /user/maria_dev/search_youtube/results/spark_correlation/part-00000-681daf95-2
665-40a8-898d-5c467408d50d-c000.csv
drwxrwxrwx - maria_dev hdfs 0 2026-06-08 19:09 /user/maria_dev/search_youtube/results/spark_keyword_summary
-rwxrwxrwx 1 maria_dev hdfs 0 2026-06-08 19:09 /user/maria_dev/search_youtube/results/spark_keyword_summary/_SUCCESS
-rwxrwxrwx 1 maria_dev hdfs 3271 2026-06-08 19:09 /user/maria_dev/search_youtube/results/spark_keyword_summary/part-00000-897638
71-96be-4e55-94bb-81e97f98d96c-c000.csv

```

4. Hive 테이블 생성

```

➔ scripts hive
SLF4J: Class path contains multiple SLF4J bindings.
SLF4J: Found binding in [jar:file:/usr/hdp/3.0.1.0-187/hive/lib/log4j-slf4j-impl-2.10.0.jar!/org/slf4j/impl/StaticLoggerBinder.class]
SLF4J: Found binding in [jar:file:/usr/hdp/3.0.1.0-187/hadoop/lib/slf4j-log4j12-1.7.25.jar!/org/slf4j/impl/StaticLoggerBinder.class]
SLF4J: See http://www.slf4j.org/codes.html#multiple_bindings for an explanation.
SLF4J: Actual binding is of type [org.apache.logging.slf4j.Log4jLoggerFactory]
Connecting to jdbc:hive2://sandbox-hdp.hortonworks.com:2181/default;password=hive;serviceDiscoveryMode=zooKeeper;user=hive;zooKeeperName
space=hiveserver2
26/06/08 20:21:48 [main]: INFO jdbc.HiveConnection: Connected to sandbox-hdp.hortonworks.com:10000
Connected to: Apache Hive (version 3.1.0.3.0.1.0-187)
Driver: Hive JDBC (version 3.1.0.3.0.1.0-187)
Transaction isolation: TRANSACTION_REPEATABLE_READ
Beeline version 3.1.0.3.0.1.0-187 by Apache Hive
0: jdbc:hive2://sandbox-hdp.hortonworks.com:2> USE search_youtube;
INFO : Compiling command(queryId=hive_20260608202150_cd0b0a50-0ef4-4575-bd89-794ccd2aec83): USE search_youtube
INFO : Semantic Analysis Completed (retrial = false)
INFO : Returning Hive schema: Schema(fieldSchemas:null, properties:null)
INFO : Completed compiling command(queryId=hive_20260608202150_cd0b0a50-0ef4-4575-bd89-794ccd2aec83): Time taken: 0.043 seconds
INFO : Executing command(queryId=hive_20260608202150_cd0b0a50-0ef4-4575-bd89-794ccd2aec83): USE search_youtube
INFO : Starting task [Stage-0:DDL] in serial mode
INFO : Completed executing command(queryId=hive_20260608202150_cd0b0a50-0ef4-4575-bd89-794ccd2aec83): Time taken: 0.018 seconds
INFO : OK
No rows affected (0.198 seconds)
0: jdbc:hive2://sandbox-hdp.hortonworks.com:2> SHOW TABLES;
INFO : Compiling command(queryId=hive_20260608202235_9f6de57d-c0b1-4991-b971-adac7577e5a7): SHOW TABLES
INFO : Semantic Analysis Completed (retrial = false)
INFO : Returning Hive schema: Schema(fieldSchemas:[FieldSchema(name:tab_name, type:string, comment:from deserializer)], properties:null)
INFO : Completed compiling command(queryId=hive_20260608202235_9f6de57d-c0b1-4991-b971-adac7577e5a7): Time taken: 0.036 seconds
INFO : Executing command(queryId=hive_20260608202235_9f6de57d-c0b1-4991-b971-adac7577e5a7): SHOW TABLES
INFO : Starting task [Stage-0:DDL] in serial mode
INFO : Completed executing command(queryId=hive_20260608202235_9f6de57d-c0b1-4991-b971-adac7577e5a7): Time taken: 0.021 seconds
INFO : OK
+-----+
| tab_name |
+-----+
| category_summary |
| correlation_result |
| keyword_summary |
+-----+
3 rows selected (0.126 seconds)

```

5. Hive 쿼리 조회

5-1. 키워드 top 10 조회

```

+-----+-----+-----+-----+
| keyword | category | avg_views_per_day | million_view_ratio |
+-----+-----+-----+-----+
| AI | IT/?? | 899696.0 | 1.0 |
| ?? | ??/?? | 329419.0 | 0.933 |
| ??? | ??/?? | 325492.0 | 1.0 |
| ??? | ??/?? | 323375.0 | 0.9 |
| ?? | ??/?? | 291610.0 | 0.4 |
| ??? | ??/?? | 289923.0 | 1.0 |
| ?? | ?? | 282380.0 | 0.8 |
| ?? | ?? | 222686.0 | 0.867 |
| ??? | IT/?? | 210674.0 | 0.3 |
| ?? | IT/?? | 202702.0 | 0.967 |
+-----+-----+-----+-----+
10 rows selected (12.985 seconds)

```

※Beeline/Hive 터미널 인코딩 문제로 한글 키워드와 분야명이 일부 깨져 표시되었으나, 수치 결과는 정상적으로 조회되었다.

보고서 표는 Spark 결과 CSV 와 Hive 조회 수치를 기준으로 한글명을 복원하여 정리하였다.

5-2. 분야별 요약 조회

category	video_count	avg_view_count	avg_views_per_day	million_view_ratio
IT/??	148	2976690.0	301491.0	0.547
??/??	149	3225323.0	252233.0	0.839
??/??	148	1422560.0	206433.0	0.615
??	150	1384853.0	158769.0	0.573

4 rows selected (7.439 seconds)

5-3. 상관관계 결과 조회.

metric	google_corr	naver_corr
avg_view_count	0.504	-0.206
avg_views_per_day	0.584	-0.152
million_view_ratio	0.348	-0.387
avg_like_count	0.449	-0.233
avg_comment_count	0.456	-0.102

5 rows selected (0.282 seconds)